3. Playing Atari with Deep Reinforcement Learning

1. Introduction
    - 논문이 다루는 분야
    - 해당 task에서 기존 연구 한계점
    - 논문의 contributions
2. Related Work
3. 제안 방법론
    - Main Idea
    - Contribution
4. 실험 및 결과
    - Dataset
    - Baseline
    - 결과
5. 결론 (배운점)

1. Introduction

논문이 다루는 분야

- 시각이나 음성 같은 고차원 감각 입력으로부터 직접 제어 정책을 학습하는 강화학습
- 특히, 사전 지식이나 수작업 특징 없이 원시 픽셀 형태의 비디오 데이터만을 입력으로 받아 미래의 보상을 추정하는 딥러닝 모델 설계

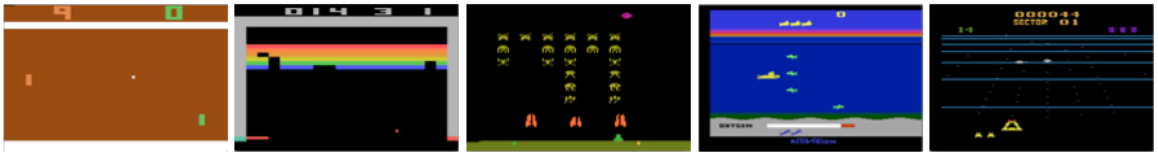

Figure 1: Screen shots from five Atari 2600 Games: (*Left-to-right*) Pong, Breakout, Space Invaders, Seaquest, Beam Rider

해당 task에서 기존 연구 한계점

- 기존 성공적인 강화학습 모델들은 수작업으로 만든 특징과 선형 가치 함수에 크게 의존하여, **성능이 특징 표현의 품질에 따라 크게 좌우**됨.
- 대량의 정답 데이터가 필요한 지도학습 기반 딥러닝과 달리, **강화학습은 희소하고 노이즈가 많으며 지연된 스칼라 보상 신호만으로 학습해야** 하는 어려움 존재.
- 일반적인 딥러닝은 데이터 샘플이 독립적이라고 가정하지만, 강화학습에서는 **연속된 상태 시퀀스들 간의 상관관계가 매우 높음**.
- 에이전트가 새로운 행동을 학습할 때마다 데이터 분포가 계속 변하므로 **고정된 데이터 분포를 가정하는 기존 딥러닝 방법론 적용 불가.**

논문의 contributions

- 고차원 감각 입력으로부터 직접 제어 정책을 성공적으로 학습한 최초의 딥러닝 모델 제시.
- 원시 픽셀을 입력으로 하는 CNN 구조와 Q-learning의 변형을 결합한 혁신적인 아키텍처 제안.
- **Experience replay 메커니즘 도입**
  이전 전환 기록을 무작위로 샘플링하여 학습함으로써 데이터 상관관계를 줄이고 훈련 분포를 부드럽게 만들어 데이터 분포가 변하는 문제를 해결함.
- **범용성 입증**
  네트워크 아키텍처나 학습 알고리즘 변경 없이 단일 모델로 7개의 서로 다른 아타리 2600 게임에 적용하여 성공적인 학습 달성.
- 6개의 게임에서 기존의 모든 강화학습 접근 방식을 뛰어넘는 성능을 보였으며, 3개의 게임에서는 인간 전문가 수준을 능가함.

2. Related Work

1) 기존 연구들에 대한 서술

- 과거 **TD-Gammon** 모델이 신경망을 활용해 백개먼 게임에서 성공했으나, 체스나 바둑 등 다른 게임에서는 번번이 실패함
- 특히 Q-learning에 비선형 함수를 결합하면 학습이 완전히 망가지는(발산하는) 문제가 있어 한동안 안전한 선형 모델 위주로만 연구가 진행됨
- 본 논문과 가장 유사하게 시각 데이터를 다룬 **NFQ 모델**은 오토인코더를 이용해 이미지를 작게 압축하는 사전 작업이 필수적이었음
- 또한 NFQ는 데이터를 통째로 묶어서 업데이트하는 방식을 사용하여 **데이터가 많아질수록 연산 비용이 지나치게 높다**는 한계가 존재함

- 기존 아타리 게임 연구들은 사람이 직접 배경을 지우는 등 힌트를 주거나, 특정 게임의 패턴만 암기하는 꼼수 위주의 진화 알고리즘에 의존함

2) 제안 방법의 차별성

- 중간에 이미지를 압축하는 준비 단계 없이, **원시 픽셀 화면만으로 모델이 직접 게임 판단에 필요한 특징을 찾아내**는 End-to-End 방식
- 무거운 업데이트 대신 가벼운 **확률적 경사 하강법**을 사용하여 대규모 데이터셋에서도 빠르고 효율적으로 학습 가능함
- 단순한 데이터에만 쓰이던 Experience replay 기법을 복잡한 고차원 시각 비디오 처리에 성공적으로 도입하여 학습을 안정화함
- 특정 게임의 버그나 정해진 패턴만 외우는 것이 아니라, 한 번도 본 적 없는 다양한 상황에서도 유연하게 대응할 수 있는 **범용적인 일반화 능력**을 입증함

3. 제안 방법론

Main Idea

Algorithm 1 Deep Q-learning with Experience Replay

Initialize replay memory $\mathcal{D}$ to capacity N
Initialize action-value function Q with random weights
for episode $= 1, M$ **do**
  Initialise sequence $s_1 = \{x_1\}$ and preprocessed sequenced $\phi_1 = \phi(s_1)$
  for $t = 1, T$ **do**
    With probability ϵ select a random action a_t
    otherwise select $a_t = \max_a Q^*(\phi(s_t), a; \theta)$
    Execute action a_t in emulator and observe reward r_t and image x_{t+1}
    Set $s_{t+1} = s_t, a_t, x_{t+1}$ and preprocess $\phi_{t+1} = \phi(s_{t+1})$
    Store transition $(\phi_t, a_t, r_t, \phi_{t+1})$ in $\mathcal{D}$
    Sample random minibatch of transitions $(\phi_j, a_j, r_j, \phi_{j+1})$ from $\mathcal{D}$
    Set $y_j = \begin{cases} r_j & \text{for terminal } \phi_{j+1} \\ r_j + \gamma \max_{a'} Q(\phi_{j+1}, a'; \theta) & \text{for non-terminal } \phi_{j+1} \end{cases}$
    Perform a gradient descent step on $(y_j - Q(\phi_j, a_j; \theta))^2$ according to equation 3
  end for
end for

Deep Q-learning 알고리즘

: 고차원 원시 픽셀을 입력으로 받아 제어 정책을 학습하기 위해 CNN과 Q-learning을 결합

- 에이전트의 매 시간 단계 경험(상태, 행동, 보상, 다음 상태)을 Experience replay 메모리에 저장하고, 여기서 무작위로 미니배치를 추출하여 Q-network를 업데이트

- 무작위 샘플링을 통해 연속된 데이터 간의 상관관계를 끊고 훈련 분포를 부드럽게 만들어, Introduction에서 제기했던 데이터 분포 변화(Non-stationary) 문제와 가치 함수 발산 위험을 성공적으로 억제
- 연산량을 줄이기 위한 전처리 과정(210x160 RGB를 84x84 흑백 이미지 4장 스택으로 변환)과 CNN의 구체적인 레이어 구성(필터 크기, 스트라이드, ReLU 등)을 명시

Contribution

- 상태와 행동을 모두 신경망의 입력으로 넣어야 했던 기존의 비효율적인 구조를 탈피
- State 이미지 하나만 입력하면 가능한 모든 행동에 대한 Q-value를 한 번의 Forward pass로 동시에 연산해 내는 효율적인 DQN(Deep Q-Network) 아키텍처 고안
- Experience replay 메커니즘을 통해 하나의 과거 경험 데이터를 가중치 업데이트에 여러 번 재사용할 수 있게 만들어 데이터 효율성을 극대화
- 그동안 불안정하다고 여겨졌던 Off-policy 강화학습 알고리즘(Q-learning)과 비선형 딥러닝 모델을 안정적으로 결합할 수 있는 실용적인 프레임워크를 성공적으로 확립

4. 실험 및 결과

1) Dataset

- Arcade Learning Environment를 활용한 7개의 아타리 2600 게임 (Beam Rider, Breakout, Enduro, Pong, Q*bert, Seaquest, Space Invaders)
- 모든 게임의 화면은 연산량 감소를 위해 84x84 크기의 흑백 이미지로 전처리하여 스택 형태로 사용함

2) Baseline

- **Random:** 무작위 행동 선택
- **Sarsa:** 수작업으로 설계된 특징(Feature)에 기반한 선형 정책 모델
- **Contingency:** Sarsa 방식에 에이전트가 제어할 수 있는 화면 영역에 대한 학습 표현을 추가한 모델
- **HNeat:** 진화 알고리즘 기반의 결정론적 정책 탐색 방식
- **Human:** 약 2시간 플레이 후 측정한 인간 전문가의 중앙값(Median) 점수

3) 결과

- **압도적인 성능 향상:** 7개 모든 게임에서 Sarsa, Contingency 등 기존의 강화학습 방법론들을 압도적인 격차로 뛰어넘음

- **인간 전문가 능가:** Breakout, Enduro, Pong 등 3개 게임에서는 인간 전문가의 점수를 초과 달성함
- **학습 안정성 증명:** 에피소드당 얻는 평균 보상 지표는 변동성이 컸지만, 모델이 예측하는 평균 Q-value는 매끄럽게 상승함을 확인하여 Experience replay를 통한 학습의 안정성을 증명함
- **완벽한 범용성 입증:** 각 게임의 특성에 맞춘 어떠한 정보 주입이나 하이퍼파라미터 튜닝 없이 오직 단일 모델만으로 이 모든 결과를 이끌어냄
- (💡 PPT 시각 자료 추천:

1. **성능 비교표:** 논문 8페이지 상단의 **Table 1** 캡처를 추천함. DQN이 다른 Baseline 및 인간 전문가와 비교해 얼마나 높은 점수를 냈는지 한눈에 보여주는 가장 핵심적인 결과표임.
2. **안정성 그래프:** 논문 7페이지 상단의 **Figure 2** 캡처를 추천함. 왼쪽의 들쭉날쭉한 보상 그래프와 대비되는 오른쪽의 매끄러운 Q-value 그래프를 통해 학습이 발산 없이 안정적으로 이루어졌음을 설명하기 좋음.)*

Dataset

- Arcade Learning Environment를 활용한 7개의 아타리 2600 게임 (Beam Rider, Breakout, Enduro, Pong, Q*bert, Seaquest, Space Invaders)
- 모든 게임의 화면은 연산량 감소를 위해 84x84 크기의 흑백 이미지로 전처리하여 스택 형태로 사용함

Baseline

- **Random:** 무작위 행동 선택
- **Sarsa:** 수작업으로 설계된 특징(Feature)에 기반한 선형 정책 모델
- **Contingency:** Sarsa 방식에 에이전트가 제어할 수 있는 화면 영역에 대한 학습 표현을 추가한 모델
- **HNeat:** 진화 알고리즘 기반의 결정론적 정책 탐색 방식
- **Human:** 약 2시간 플레이 후 측정한 인간 전문가의 중앙값(Median) 점수

결과

- 7개 모든 게임에서 Sarsa, Contingency 등 **기존의 강화학습 방법론들을 압도적인 격차로 뛰어넘음**

	B. Rider	Breakout	Enduro	Pong	Q*bert	Seaquest	S. Invaders
Random	354	1.2	0	−20.4	157	110	179
Sarsa [3]	996	5.2	129	−19	614	665	271
Contingency [4]	1743	6	159	−17	960	723	268
DQN	**4092**	**168**	**470**	**20**	**1952**	**1705**	**581**
Human	7456	31	368	−3	18900	28010	3690
HNeat Best [8]	3616	52	106	19	1800	920	**1720**
HNeat Pixel [8]	1332	4	91	−16	1325	800	1145
DQN Best	**5184**	**225**	**661**	**21**	**4500**	**1740**	1075

- Breakout, Enduro, Pong 등 3개 게임에서는 **인간 전문가의 점수를 초과 달성**함
- 에피소드당 얻는 평균 보상 지표는 변동성이 컸지만, 모델이 예측하는 평균 Q-value는 매끄럽게 상승함을 확인하여 Experience replay를 통한 **학습의 안정성을 증명**함

  (아래 figure : 우측 매끄러운 그래프로 안정성 증명)

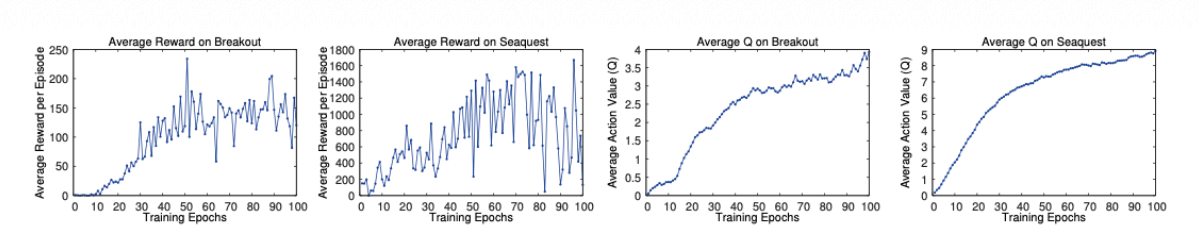

- 각 게임의 특성에 맞춘 어떠한 정보 주입이나 하이퍼파라미터 튜닝 없이 **오직 단일 모델만**으로 이 모든 결과를 이끌어냄

Figure 3: The leftmost plot shows the predicted value function for a 30 frame segment of the game Seaquest. The three screenshots correspond to the frames labeled by A, B, and C respectively.

5. 결론 (배운점)

1) 연구의 의의 및 한계점

- 사람이 직접 특징을 설계할 필요 없이, 화면의 픽셀 데이터만 보고도 AI가 스스로 게임 제어 정책을 학습하는 모델을 최초로 성공시킴

- 기존에는 불안정하다고 여겨졌던 딥러닝과 강화학습의 결합을 Experience replay 메커니즘을 통해 안정적으로 구현해내며 강화학습 분야의 새로운 표준을 제시함
- 다만 여러 게임에 동일한 모델을 적용하기 위해 모든 긍정적 보상을 1, 부정적 보상을 -1로 획일화하여 보상의 규모 차이를 에이전트가 인지하지 못한다는 한계가 있음
- 먼 미래를 내다보고 장기적인 전략을 세워야 하는 스페이스 인베이더 같은 일부 게임에서는 여전히 인간 전문가의 수준에 크게 미치지 못함
- Experience replay 메모리가 단순히 오래된 데이터를 지우고 균일하게 무작위 추출할 뿐, 학습에 더 유용한 핵심 경험을 우선적으로 뽑아 쓰는 정교한 샘플링 전략까지는 갖추지 못함

- **좋았던 점**
  정답이 명확하지 않고 보상마저 지연되는 까다로운 문제를, 데이터가 들어오는 순서를 뒤섞어버리며 직관적으로 돌파한 점이 인상 깊음
- **아쉬웠던 점**
  모델이 장기적인 계획을 세우며 게임의 맥락을 이해한다기보다는 특정 화면 패턴에 대해 반사적으로 행동하도록 학습된 수준에 가깝다는 생각이 들었음.
- **배운 점**
  인공지능 과목 수업에서는 지도학습만 집중적으로 배워서 강화학습을 잘 몰랐는데, 해당 논문에서 강화학습의 로직과 게임에 적용하는 것에서의 흥미를 느끼고 더 공부하고 싶어짐

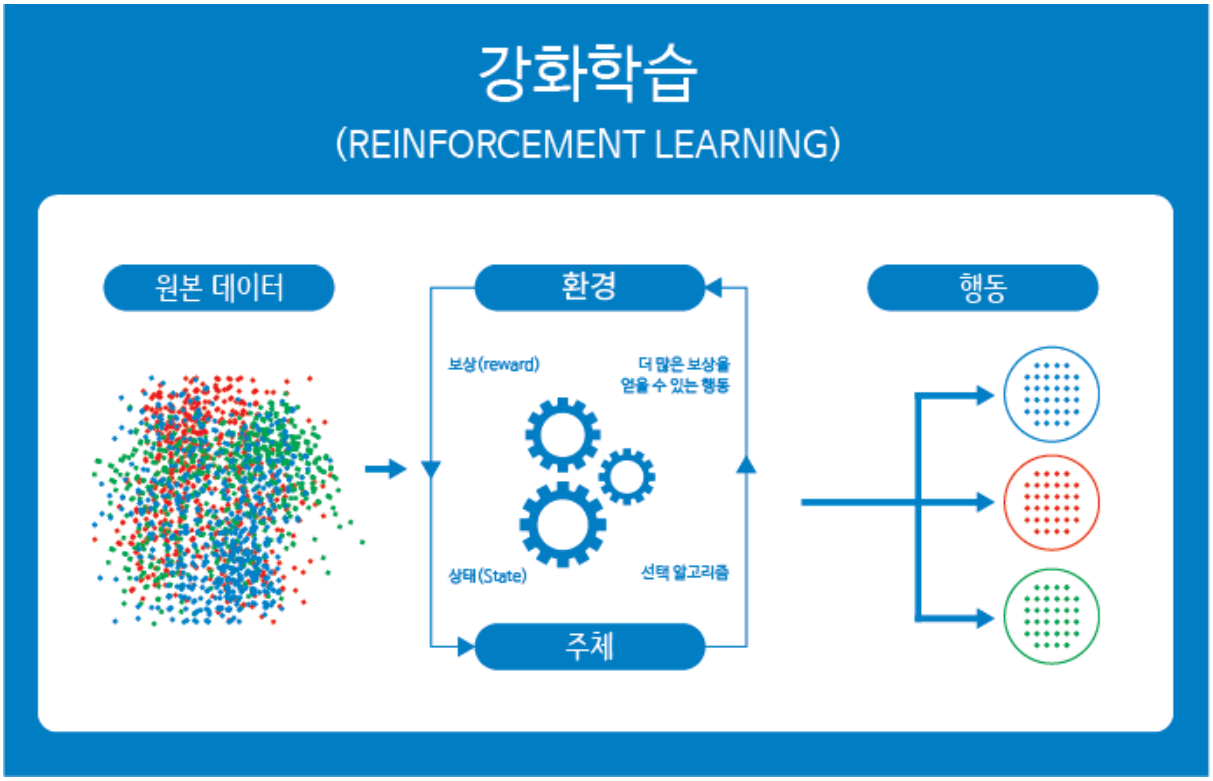
강화학습
(REINFORCEMENT LEARNING)
원본 데이터
환경
행동
보상(reward)
더 많은 보상을
얻을 수 있는 행동
상태(State)
선택 알고리즘
주체